

# Algoritmos e Estruturas de Dados I

## Aula 02: Análise de Algoritmos

Prof. Márcio Porto Basgalupp

*créditos: Prof. Jurandy G. Almeida Jr.*

Universidade Federal de São Paulo  
Departamento de Ciência e Tecnologia

# Como escolher o algoritmo mais adequado para uma situação?

- Analisar um algoritmo consiste em “verificar” o que?
  - **Tempo** de Execução
  - **Espaço** Ocupado
- Esta análise é necessária para escolher o algoritmo mais adequado para resolver um dado problema.
- É especialmente importante em áreas como pesquisa operacional, otimização, teoria dos grafos, estatística, probabilidades, entre outras.

## ■ Cálculo do Custo pela Execução do Algoritmo

- Tal medida é bastante **inadequada** e o resultado não pode ser generalizado
- Os resultados são dependentes do compilador, que pode favorecer algumas construções em detrimento de outras
- Os resultados dependem do *hardware*
- Quando grandes quantidades de memória são utilizadas, as medidas de tempo podem depender deste aspecto

- **Cálculo do Custo pela Execução do Algoritmo**
  - Apesar disso, há argumentos a favor de se obterem medidas reais de tempo
  - Ex.: quando há vários algoritmos distintos para resolver um mesmo tipo de problema, todos com um custo de execução dentro de uma mesma **ordem de grandeza**

- Possibilidade de analisar:
  - Um **algoritmo** particular
  - Uma **classe** de algoritmos

- Análise de um **algoritmo particular**
  - Qual é o custo de usar um dado algoritmo para um resolver um problema específico?
  - Características que devem ser investigadas:
    - Análise do número de vezes que cada parte do algoritmo deve ser executada (**tempo**)
    - Estudo da quantidade de memória necessária (**espaço**)

- Análise de uma **classe de algoritmos**
  - Qual é o algoritmo de menor custo possível para resolver um problema particular?
  - Toda uma família de algoritmos é investigada
  - Procura-se identificar um que seja o melhor possível
  - Coloca-se **limites** para a complexidade computacional dos algoritmos pertencentes à classe



- O menor custo possível para resolver problemas de uma classe nos dá a dificuldade inerente para resolver o problema
- Quando o custo de um algoritmo é igual ao menor custo possível, o algoritmo é **ótimo** para a medida de custo considerada
  - Podem existir vários algoritmos ótimos para resolver o mesmo problema
- Se a mesma medida de custo é aplicada a diferentes algoritmos, então é possível compará-los e escolher o mais adequado

- Utilizaremos um modelo matemático baseado em um computador idealizado
- Deve ser especificado o conjunto de operações e seus custos de execuções
- É mais usual ignorar o custo de algumas operações e considerar apenas outras mais significativas
- Ex.: algoritmos de ordenação. Considera-se o **número de comparações** entre os elementos do conjunto a ser ordenado e ignoramos as demais operações

- Para medir o custo de execução de um algoritmo vamos definir uma **função de complexidade** ou função de custo  **$f$**
- Função de **complexidade de tempo**:  $f(n)$  mede o tempo necessário para executar um algoritmo em um problema de tamanho  $n$
- Função de **complexidade de espaço**:  $f(n)$  mede a memória necessária para executar um algoritmo em um problema de tamanho  $n$

- Utilizaremos  $f$  para denotar uma função de complexidade de tempo daqui para a frente
- A complexidade de tempo na realidade não representa tempo diretamente
  - Representa o número de vezes que determinadas operações relevantes são executadas

# Exemplo: Maior Elemento

- Considere o algoritmo para encontrar o maior elemento de um vetor de inteiros  $A[n]$ ,  $n \geq 1$

```
int Max(int* A, int n) {  
    int i, Temp;  
  
    Temp = A[0];  
    for (i = 1; i < n; i++)  
        if (Temp < A[i])  
            Temp = A[i];  
    return Temp;  
}
```

- Seja  $f$  uma função de complexidade tal que  $f(n)$  é o número de comparações envolvendo os elementos de  $A$ , se  $A$  contiver  $n$  elementos. Qual é a função  $f(n)$ ?

# Exemplo: Maior Elemento

- Considere o algoritmo para encontrar o maior elemento de um vetor de inteiros  $A[n]$ ,  $n \geq 1$

```
int Max(int* A, int n) {  
    int i, Temp;  
  
    Temp = A[0];  
    for (i = 1; i < n; i++)  
        if (Temp < A[i])  
            Temp = A[i];  
    return Temp;  
}
```

**(n-1)**

- Seja  **$f$**  uma função de complexidade tal que  **$f(n)$**  é o número de comparações envolvendo os elementos de  $A$ , se  $A$  contiver  $n$  elementos. **Qual é a função  $f(n)$ ?**

## Teorema

Qualquer algoritmo para encontrar o maior elemento de um conjunto com  $n$  elementos,  $n \geq 1$ , faz pelo menos  $n - 1$  comparações.

## Teorema

Qualquer algoritmo para encontrar o maior elemento de um conjunto com  $n$  elementos,  $n \geq 1$ , faz pelo menos  $n - 1$  comparações.

O teorema acima nos diz que, se o número de comparações for utilizado como medida de custo, então a função Max do programa anterior é **ótima**.



- A medida do custo de execução de um algoritmo **depende principalmente** do tamanho da entrada dos dados
- É comum considerar o tempo de execução de um programa como uma função do tamanho da entrada
- Para alguns algoritmos, o custo de execução é uma função da entrada particular dos dados, não apenas do tamanho da entrada

- No caso da função Max do programa do exemplo, o **custo é uniforme** sobre todos os problemas de tamanho  $n$
- Já para um **algoritmo de ordenação** isso não ocorre: se os dados de entrada já estiverem quase ordenados, então pode ser que o algoritmo trabalhe menos

- **Melhor caso:** menor tempo de execução sobre todas as entradas de tamanho  $n$
- **Pior caso:** maior tempo de execução sobre todas as entradas de tamanho  $n$
- **Caso médio** (ou caso esperado): média dos tempos de execução de todas as entradas de tamanho  $n$

$$\text{Melhor Caso} \leq \text{Caso Médio} \leq \text{Pior Caso}$$

- Na análise do caso médio, supõe-se uma **distribuição de probabilidades** sobre o conjunto de entradas de tamanho  $n$  sobre a qual o custo esperado é obtido
- A análise do caso médio é geralmente mais difícil de se obter do que as análises do melhor e do pior caso
- É comum supor uma distribuição de probabilidades em que todas as entradas são igualmente prováveis
  - Na prática, isso nem sempre é verdade!

# Ex.: Maior e Menor Elemento (1)

- Considere o problema de encontrar o maior e o menor elemento de um vetor de inteiros  $A[n]$ ,  $n \geq 1$

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Qual a Função de Complexidade?

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Qual a Função de Complexidade?

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Qual a Função de Complexidade?

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

$2*(n-1)$



# Qual a Função de Complexidade?

- Seja  $f(n)$  o número de comparações entre os elementos de  $A$ . Logo,  $f(n) = 2(n - 1)$  para o melhor caso, pior caso e caso médio.

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Ex.: Maior e Menor Elemento (2)

- MinMax1 pode ser facilmente melhorado: a comparação  $A[i] < *pMin$  só é necessária quando a comparação  $A[i] > *pMax$  dá falso.

```
void MaxMin2(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        else if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Qual a Função de Complexidade?

## ■ Melhor caso:

- quando os elementos estão em ordem crescente
- $f(n) = n - 1$

## ■ Pior caso:


- quando o maior elemento é o primeiro no vetor
- $f(n) = 2(n - 1)$

## ■ Caso médio:

- $A[i]$  é maior do que Max a metade das vezes
- $f(n) = 1,5(n-1) = 3/2 (n-1) = 3n/2 - 3/2$

# Ex.: Maior e Menor Elemento (3)

- Considerando o número de comparações realizadas, é possível obter um algoritmo mais eficiente:
  - Compare os elementos de A aos pares, separando-os em dois subconjuntos (maiores em um e menores em outro), a um custo de  $\lceil n/2 \rceil$  comparações.
  - O máximo é obtido do subconjunto que contém os maiores elementos, a um custo de  $\lceil n/2 \rceil - 1$  comparações.
  - O mínimo é obtido do subconjunto que contém os menores elementos, a um custo de  $\lceil n/2 \rceil - 1$  comparações.



# Ex.: Maior e Menor Elemento (3)

```
void MaxMin3(int* A, int n, int* pMax, int* pMin)
{
    int i;

    if ((n % 2) > 0)          { *pMax = A[n-1]; *pMin = A[n-1]; }
    else
    {
        if (A[n-2] > A[n-1]) { *pMax = A[n-2]; *pMin = A[n-1]; } → Comparação 1
        else                 { *pMax = A[n-1]; *pMin = A[n-2]; }
    }

    for (i = 1; i < n-1; i += 2)
    {
        if (A[i - 1] > A[i]) → Comparação 2
        {
            if (A[i - 1] > *pMax) *pMax = A[i - 1]; → Comparação 3
            if (A[i] < *pMin) *pMin = A[i]; → Comparação 4
        }
        else
        {
            if (A[i - 1] < *pMin) *pMin = A[i - 1]; → Comparação 3
            if (A[i] > *pMax) *pMax = A[i]; → Comparação 4
        }
    }
}
```

- Quantas comparações são feitas em MaxMin3?
  - 1ª comparação feita 1 vez
  - 2ª comparação feita  $n/2 - 1$  vezes
  - 3ª e 4ª comparações feitas  $n/2 - 1$  vezes

$$f(n) = 1 + n/2 - 1 + 2 * (n/2 - 1)$$

$$f(n) = (3n - 6)/2 + 1$$

$$f(n) = 3n/2 - 3 + 1 = 3n/2 - 2$$

No pior caso, melhor caso e caso médio

# Comparação entre os Algoritmos

- A tabela apresenta uma comparação entre os algoritmos dos programas MaxMin1, MaxMin2 e MaxMin3, considerando o número de comparações como medida de complexidade
- Os algoritmos MaxMin2 e MaxMin3 são superiores ao algoritmo MaxMin1 de forma geral.
- O algoritmo MaxMin3 é superior ao algoritmo MaxMin2 com relação ao pior caso e bastante próximo quanto ao caso médio

Os três algoritmos	$f(n)$		
	Melhor caso	Pior caso	Caso médio
MaxMin1	$2(n - 1)$	$2(n - 1)$	$2(n - 1)$
MaxMin2	$n - 1$	$2(n - 1)$	$3n/2 - 3/2$
MaxMin3	$3n/2 - 2$	$3n/2 - 2$	$3n/2 - 2$


- O parâmetro  $n$  fornece uma medida de dificuldade para se resolver o problema
- Para valores suficientemente pequenos de  $n$ , qualquer algoritmo custa pouco para ser executado
- A **escolha do algoritmo** não é um problema crítico para problemas de tamanho pequeno
- Logo, a análise de algoritmos é realizada para valores grandes de  $n$



- Para isso, estuda-se o **comportamento assintótico** das funções de custo
  - Comportamento de suas funções de custo para valores suficientemente grandes de  **$n$**
- O comportamento assintótico de  **$f(n)$**  representa o limite do comportamento do custo quando  **$n$**  cresce

- A análise de um algoritmo geralmente conta apenas com algumas operações elementares
- A medida de custo ou medida de complexidade relata o **crescimento assintótico** da operação considerada
- **Definição:** Uma função  **$f(n)$**  **domina assintoticamente** uma outra função  **$g(n)$**  se:
  - Existem duas constantes positivas  **$c$**  e  **$m$**  tais que, para  **$n \geq m$** , temos  **$|g(n)| \leq c |f(n)|$**

- **$f(n)$  domina assintoticamente  $g(n)$**  se:
  - Existem duas constantes positivas  **$c$**  e  **$m$**  tais que, para  **$n \geq m$** , temos  **$|g(n)| \leq c |f(n)|$**



- Sejam  $g(n) = (n + 1)^2$  e  $f(n) = n^2$
- As funções  $g(n)$  e  $f(n)$  dominam assintoticamente uma a outra desde que

$$|(n + 1)^2| \leq 4 |n^2| \text{ para } n \geq 1$$

e

$$|n^2| \leq |(n + 1)^2| \text{ para } n \geq 0$$

- Sejam  $g(n) = (n + 1)^2$  e  $f(n) = n^2$
- As funções  $g(n)$  e  $f(n)$  dominam assintoticamente uma a outra desde que

$$|g(n)| \leq c |f(n)|, \text{ para } n \geq m$$

$$c = 4 \text{ e } m = 1$$

$$|(n + 1)^2| \leq 4 |n^2| \text{ para } n \geq 1$$

e

$$|n^2| \leq |(n + 1)^2| \text{ para } n \geq 0$$

# Exemplo

- Sejam  $g(n) = (n + 1)^2$  e  $f(n) = n^2$
- As funções  $g(n)$  e  $f(n)$  dominam assintoticamente uma a outra desde que

$$|(n + 1)^2| \leq 4 |n^2| \text{ para } n \geq 1$$

e


$$|n^2| \leq |(n + 1)^2| \text{ para } n \geq 0$$

$$|g(n)| \leq c |f(n)|, \text{ para } n \geq m$$

$$c = 1 \text{ e } m = 0$$


- Escrevemos  $g(n) = O(f(n))$  para expressar que  $f(n)$  domina assintoticamente  $g(n)$ 
  - Lê-se:  $g(n)$  é da ordem no máximo  $f(n)$
- Exemplo:
  - Quando dizemos que o tempo de execução  $T(n)$  de um programa é  $O(n^2)$ , significa que existem constantes  $c$  e  $m$ , tais que, para valores de  $n \geq m$ ,  $T(n) \leq c n^2$

- Exemplo de gráfico de dominação assintótica que ilustra a notação O
  - Abaixo, a função  $f(n)$  domina assintoticamente a função  $g(n)$





- O valor da constante  $m$  mostrado é o menor valor possível, mas qualquer valor maior também é válido
- **Definição:** uma função  $g(n)$  é  $O(f(n))$  se existem duas constantes positivas  $c$  e  $m$  tais que  $g(n) \leq c f(n)$ , para todo  $n \geq m$



# Exemplo de Notação O

- Exemplo:  $g(n) = (n + 1)^2$ 
  - Logo,  $g(n)$  é  $O(n^2)$  quando  $m = 1$  e  $c = 4$
  - Isto porque  $(n + 1)^2 \leq 4 n^2$  para  $n \geq 1$

# Exemplo de Notação O

- Exemplo:  $g(n) = (n + 1)^2$ 
  - Logo,  $g(n)$  é  $O(n^2)$  quando  $m = 1$  e  $c = 4$
  - Isto porque  $(n + 1)^2 \leq 4 n^2$  para  $n \geq 1$

existe **c** tal que  
 **$g(n) \leq c f(n)$**   
para  **$n \geq m$**

# Exemplo de Notação O

- Exemplo:  $g(n) = n$  e  $f(n) = n^2$ 
  - Sabemos que  $g(n)$  é  $O(n^2)$ , pois para  $n \geq 1$ ,  $n \leq n^2$
  - Entretanto,  $f(n)$  não é  $O(n)$
  - Suponha que existam constantes  $c$  e  $m$  tais que para todo  $n \geq m$ ,  $n^2 \leq c n$
  - Se  $c \geq n$  para qualquer  $n \geq m$ , então deveria existir um valor para  $c$  que possa ser maior ou igual  $n$  para todo  $n$

# Exemplo de Notação O

- Exemplo:  $g(n) = n$  e  $f(n) = n^2$ 
  - Sabemos que  $g(n)$  é  $O(n^2)$ , pois para  $n \geq 1$ ,  $n \leq n^2$
  - Entretanto,  $f(n)$  não é  $O(n)$
  - Suponha que existam constantes  $c$  e  $m$  tais que para todo  $n \geq m$ ,  $n^2 \leq c n$
  - Se  $c \geq n$  para qualquer  $n \geq m$ , então deveria existir um valor para  $c$  que possa ser maior ou igual  $n$  para todo  $n$

**não existe  $c$  tal que**  
 **$g(n) \leq c f(n)$**   
**para  $n \geq m$**

- Exemplo:  $g(n) = 3n^3 + 2n^2 + n$  é  $O(n^3)$ 
  - Basta mostrar que  $3n^3 + 2n^2 + n \leq 6n^3$  para  $n \geq 0$
  - A função  $g(n) = 3n^3 + 2n^2 + n$  é também  $O(n^4)$ , entretanto, essa afirmação é mais fraca do que dizer que  $g(n)$  é  $O(n^3)$

- Exemplo:  $g(n) = 3n^3 + 2n^2 + n$  é  $O(n^3)$ 
  - Basta mostrar que  $3n^3 + 2n^2 + n \leq 6n^3$  para  $n \geq 0$
  - A função  $g(n) = 3n^3 + 2n^2 + n$  é também  $O(n^4)$ , entretanto, essa afirmação é mais fraca do que dizer que  $g(n)$  é  $O(n^3)$

**existe  $c$  tal que**  
 **$g(n) \leq c f(n)$**   
**para  $n \geq m$**

- Exemplo:  $g(n) = 3n^3 + 2n^2 + n$  é  $O(n^3)$ 
  - Basta mostrar que  $3n^3 + 2n^2 + n \leq 6n^3$  para  $n \geq 0$
  - A função  $g(n) = 3n^3 + 2n^2 + n$  é também  $O(n^4)$ , entretanto, essa afirmação é mais fraca do que dizer que  $g(n)$  é  $O(n^3)$
- Pergunta:  $g(n)$  é  $O(n^{40})$ ?

existe **c** tal que  
 $g(n) \leq c f(n)$   
para  $n \geq m$



# Exemplo de Notação O

- Exemplo:  $g(n) = \log_5 n$  é  $O(\log n)$ 
  - O  $\log_a n$  difere do  $\log_b n$  por uma constante  $c = \log_a b$
  - Como  $n = b^{\log_b n}$ , tomando o logaritmo base  $a$  em ambos os lados da igualdade, temos que

$$\log_a n = \log_a b^{\log_b n}$$

$$\log_a n = \log_a b \times \log_b n$$

# Exemplo de Notação O

- Exemplo:  $g(n) = \log_5 n$  é  $O(\log n)$ 
  - O  $\log_a n$  difere do  $\log_b n$  por uma constante  $c = \log_a b$
  - Como  $n = b^{\log_b n}$ , tomando o logaritmo base  $a$  em ambos os lados da igualdade, temos que

$$\log_a n = \log_a b^{\log_b n}$$

$$\log_a n = \log_a b \times \log_b n$$

existe  **$c$**  tal que  
 **$g(n) \leq c f(n)$**   
para  **$n \geq m$**

# Qual a Complexidade Assintótica?

- Seja  $f(n)$  o número de comparações entre os elementos de  $A$ . Logo,  $f(n) = 2(n - 1)$  para o melhor caso, pior caso e caso médio.

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

# Qual a Complexidade Assintótica?

- Seja  $f(n)$  o número de comparações entre os elementos de  $A$ . Logo,  $f(n) = 2(n - 1)$  para o melhor caso, pior caso e caso médio.

```
void MaxMin1(int* A, int n, int* pMax, int* pMin)
{
    int i;

    *pMax = A[0];
    *pMin = A[0];
    for (i = 1; i < n; i++) {
        if (A[i] > *pMax) *pMax = A[i];
        if (A[i] < *pMin) *pMin = A[i];
    }
}
```

$O(n)$

# Exemplo: Algoritmos MaxMin

Os três algoritmos	$f(n)$		
	Melhor caso	Pior caso	Caso médio
MaxMin1	$2(n - 1)$	$2(n - 1)$	$2(n - 1)$
MaxMin2	$n - 1$	$2(n - 1)$	$3n/2 - 3/2$
MaxMin3	$3n/2 - 2$	$3n/2 - 2$	$3n/2 - 2$

- Todos os algoritmos têm a mesma complexidade assintótica, ou seja, são  $O(n)$

# Operações com a Notação O

$$f(n) = O(f(n))$$

$$c \times O(f(n)) = O(f(n)) \quad c = \text{constante}$$

$$O(f(n)) + O(f(n)) = O(f(n))$$

$$O(O(f(n))) = O(f(n))$$

$$O(f(n)) + O(g(n)) = O(\max(f(n), g(n)))$$

$$O(f(n))O(g(n)) = O(f(n)g(n))$$

$$f(n)O(g(n)) = O(f(n)g(n))$$

- Exemplo: regra da soma  $O(f(n)) + O(g(n))$ 
  - Suponha três trechos cujos tempos de execução são  $O(n)$ ,  $O(n^2)$  e  $O(n \log n)$
  - O tempo de execução dos dois primeiros trechos é  $O(\max(n, n^2))$ , que é  $O(n^2)$
  - O tempo de execução de todos os três trechos é então  $O(\max(n^2, n \log n))$ , que é  $O(n^2)$

- Se  $f$  é uma função de complexidade para um algoritmo  $F$ , então  $O(f)$  é considerada a complexidade assintótica ou o comportamento assintótico do algoritmo  $F$
- A relação de dominação assintótica permite comparar funções de complexidade
  - Entretanto, se as funções  $f$  e  $g$  dominam assintoticamente uma a outra, então os algoritmos associados são equivalentes
  - Nesses casos, o comportamento assintótico não serve para comparar os algoritmos



## ■ Exemplo:

- Considere dois algoritmos  $F$  e  $G$ , em que  $F$  leva três vezes o tempo de  $G$ , isto é,  $f(n) = 3 g(n)$ , portanto,  $O(f(n)) = O(g(n))$
- Logo, o comportamento assintótico não serve para comparar os algoritmos  $F$  e  $G$ , porque eles diferem apenas por uma constante
- Nesse caso, podemos avaliar algoritmos comparando as funções de complexidade, negligenciando as constantes de proporcionalidade

- Um algoritmo com tempo de execução  $O(n)$  é melhor que outro com tempo  $O(n \log_{10} n)$
- Porém, as constantes de proporcionalidade podem alterar esta consideração
- Exemplo:
  - Um algoritmo leva  $100n$  unidades de tempo para ser executado e outro leva  $n \log_{10} n$ . Qual dos dois é melhor?
  - **Depende do tamanho do problema**
    - O algoritmo com tempo  $100n$  é melhor do que o que possui tempo  $n \log_{10} n$  para  $n \geq 10^{100}$
    - $10^{100} \approx$  número de átomos do universo observável

## ■ $f(n) = O(1)$

- Algoritmos de complexidade  $O(1)$  são ditos de **complexidade constante**
- Uso do algoritmo independe de  $n$
- As instruções do algoritmo são executadas um número fixo de vezes

## ■ $f(n) = O(\log n)$

- Um algoritmo de complexidade  $O(\log n)$  é dito ter **complexidade logarítmica**
- Típico em algoritmos que transformam um problema em outros menores
- Pode-se considerar o tempo de execução como menor que uma constante grande
- Quando  $n$  é mil,  $\log_2 n = 10$ , quando  $n$  é 1 milhão,  $\log_2 n = 20$ 
  - Para dobrar o valor de  $\log n$  temos de considerar o quadrado de  $n$
- A base do logaritmo muda pouco estes valores
  - quando  $n$  é 1 milhão, o  $\log_2 n$  é 20 e o  $\log_{10} n$  é 6

## ■ $f(n) = O(n)$

- Um algoritmo de complexidade  $O(n)$  é dito ter **complexidade linear**
- Em geral, um pequeno trabalho é realizado sobre cada elemento de entrada
- É a melhor situação possível para um algoritmo que tem de processar/produzir  $n$  elementos de entrada/saída
- Cada vez que  $n$  dobra de tamanho, o tempo de execução dobra

## ■ $f(n) = O(n \log n)$

- Típico em algoritmos que quebram um problema em outros menores, resolvem cada um deles independentemente e combina as soluções depois
- Quando  $n$  é 1 milhão,  $n \log_2 n$  é cerca de 20 milhões
- Quando  $n$  é 2 milhões,  $n \log_2 n$  é cerca de 42 milhões, pouco mais do que o dobro

## ■ $f(n) = O(n^2)$

- Um algoritmo de complexidade  $O(n^2)$  é dito ter **complexidade quadrática**
- Ocorrem quando os itens de dados são processados aos pares, muitas vezes em um laço dentro de outro
- Quando  $n$  é mil, o número de operações é da ordem de 1 milhão
- Sempre que  $n$  dobra, o tempo de execução é multiplicado por 4
- Úteis para resolver problemas de tamanhos relativamente pequenos

## ■ $f(n) = O(n^3)$

- Um algoritmo de complexidade  $O(n^3)$  é dito ter **complexidade cúbica**
- Úteis apenas para resolver pequenos problemas
- Quando  $n$  é 100, o número de operações é da ordem de 1 milhão
- Sempre que  $n$  dobra, o tempo de execução fica multiplicado por 8



## ■ $f(n) = O(2^n)$

- Um algoritmo de complexidade  $O(2^n)$  é dito ter **complexidade exponencial**
- Geralmente não são úteis sob o ponto de vista prático
- Ocorrem na solução de problemas quando se usa força bruta para resolvê-los
- Quando  $n$  é 20, o tempo de execução é cerca de 1 milhão
- Quando  $n$  dobra, o tempo fica elevado ao quadrado

## ■ $f(n) = O(n!)$

- Um algoritmo de complexidade  $O(n!)$  é dito ter complexidade exponencial, apesar de  $O(n!)$  ter comportamento muito pior do que  $O(2^n)$
- Geralmente ocorrem quando se usa força bruta para na solução do problema
  - $n = 20 \rightarrow 20! = 2432902008176640000$ , um número com 19 dígitos
  - $n = 40 \rightarrow$  um número com 48 dígitos

# Comparação de Funções de Custo

Função de custo	Tamanho $n$					
	10	20	30	40	50	60
$n$	0,00001 s	0,00002 s	0,00003 s	0,00004 s	0,00005 s	0,00006 s
$n^2$	0,0001 s	0,0004 s	0,0009 s	0,0016 s	0,0035 s	0,0036 s
$n^3$	0,001 s	0,008 s	0,027 s	0,64 s	0,125 s	0.316 s
$n^5$	0,1 s	3,2 s	24,3 s	1,7 min	5,2 min	13 min
$2^n$	0,001 s	1 s	17,9 min	12,7 dias	35,7 anos	366 séc.
$3^n$	0,059 s	58 min	6,5 anos	3855 séc.	$10^8$ séc.	$10^{13}$ séc.

# Comparação de Funções de Custo

Função de custo de tempo	Computador atual	Computador 100 vezes mais rápido	Computador 1.000 vezes mais rápido
$n$	$t_1$	$100 t_1$	$1000 t_1$
$n^2$	$t_2$	$10 t_2$	$31,6 t_2$
$n^3$	$t_3$	$4,6 t_3$	$10 t_3$
$2^n$	$t_4$	$t_4 + 6,6$	$t_4 + 10$

- Determinar o tempo de execução de um programa pode ser um problema matemático complexo
- Determinar a ordem do tempo de execução, sem preocupação com o valor da constante envolvida, pode ser uma tarefa mais simples
- A análise utiliza técnicas de matemática discreta, envolvendo contagem ou enumeração dos elementos de um conjunto

- Comando de atribuição, de leitura ou de escrita:  $O(1)$
- Sequência de comandos: determinado pelo maior tempo de execução de qualquer comando da sequência
- Comando de decisão: tempo dos comandos dentro do comando condicional, mais tempo para avaliar a condição, que é  $O(1)$
- Laço: soma do tempo de execução do corpo do laço mais o tempo de avaliar a condição para terminação, multiplicado pelo número de iterações

- Procedimentos não recursivos:
  - cada um deve ser computado separadamente um a um
  - inicie com os que não chamam outros procedimentos
  - avalie então os que chamam os já avaliados
  - o processo é repetido até chegar no programa principal

# Exercício


```
void exercicio1(int n)
{
    int i, a;
    a=0; i=0;
    while (i<n)
    {
        a+=i;
        i+=2;
    }
}
```

```
void exercicio2(int n)
{
    int i, j, a;
    a=0;
    for (i=0; i<n; i++)
        for (j=0; j<i; j++)
            a+=i+j;
}
```



# Exercício

```
void exercicio1(int n)
{
    int i, a;
    a=0; i=0;
    while (i<n)
    {
        a+=i;
        i++;
    }
}
```



$$\left[ \frac{n}{2} \right]$$


$O(n)$

```
void exercicio2(int n)
{
    int i, j, a;
    a=0;
    for (i=0; i<n; i++)
        for (j=0; j<i; j++)
            a+=i+j;
}
```




$$\sum_{i=0}^{n-1} i = 0 + 1 + \dots + n - 1 = \frac{n(n-1)}{2}$$

$O(n^2)$



CORMEN, T. H.; LEISERSON, C. E.; RIVEST, R. L.; STEIN, C. **Introduction to Algorithms**. 3<sup>a</sup> Edição. MIT Press, 2009. **Capítulo 3**



ZIVIANI, N. **Projeto de Algoritmos com Implementações em Pascal e C**. 3<sup>a</sup> Edição. Cengage Learning, 2010. **Seções 1.3 e 1.4**